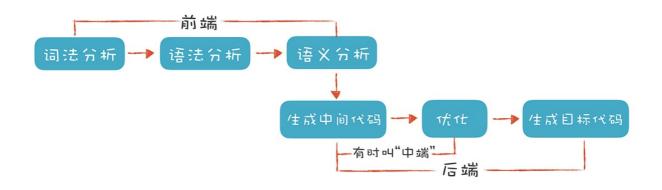
01-理解代码:编译器的前端技术

在开篇词里,我分享了一些使用编译技术的场景。其中有的场景,你只要掌握编译器的前端技术就能解决。 比如文本分析场景,软件需要用户自定义功能的场景以及前端编程语言的翻译场景等。而且咱们大学讲的编 译原理,也是侧重讲解前端技术,可见编译器的前端技术有多么重要。

当然了,**这里的"前端"指的是编译器对程序代码的分析和理解过程。**它通常只跟语言的语法有关,跟目标 机器无关。**而与之对应的"后端"则是生成目标代码的过程,跟目标机器有关。**为了方便你理解,我用一张 图直观地展现了编译器的整个编译过程。



你可以看到,编译器的"前端"技术分为**词法分析、语法分析**和**语义分析**三个部分。而它主要涉及自动机和 形式语言方面的基础的计算理论。

这些抽象的理论也许会让你"撞墙",不过不用担心,我今天会把难懂的理论放到一边,用你听得懂的大白 话,联系实际使用的场景,带你直观地理解它们,让你学完本节课之后,实现以下目标:

- 对编译过程以及其中的技术点有个宏观、概要的了解。
- 能够在大脑里绘制一张清晰的知识地图,以应对工作需要。比如分析一个日志文件时,你能知道所对应的 技术点,从而针对性地解决问题。

好了,接下来让我们正式进入今天的课程吧!

词法分析

通常,编译器的第一项工作叫做词法分析。就像阅读文章一样,文章是由一个个的中文单词组成的。程序处 理也一样,只不过这里不叫单词,而是叫做"词法记号",英文叫Token。我嫌"词法记号"这个词太长, 后面直接将它称作Token吧。

举个例子,看看下面这段代码,如果我们要读懂它,首先要怎么做呢?

```
#include <stdio.h>
int main(int argc, char* argv[]){
   int age = 45;
   if (age >= 17+8+20) {
        printf("Hello old man!\\n");
   }
        printf("Hello young man!\\n");
```

```
}
return 0;
}
```

我们会识别出if、else、int这样的关键字,main、printf、age这样的标识符,+、-、=这样的操作符号,还 有花括号、圆括号、分号这样的符号,以及数字字面量、字符串字面量等。这些都是Token。

那么,如何写一个程序来识别Token呢?可以看到,英文内容中通常用空格和标点把单词分开,方便读者阅读和理解。但在计算机程序中,仅仅用空格和标点分割是不行的。比如"age >= 45"应该分成"age"">="和"45"这三个Token,但在代码里它们可以是连在一起的,中间不用非得有空格。

这和汉语有点儿像,汉语里每个词之间也是没有空格的。但我们会下意识地把句子里的词语正确地拆解出来。比如把"我学习编程"这个句子拆解成"我""学习""编程",这个过程叫做"分词"。如果你要研发一款支持中文的全文检索引擎,需要有分词的功能。

其实,我们可以通过制定一些规则来区分每个不同的Token,我举了几个例子,你可以看一下。

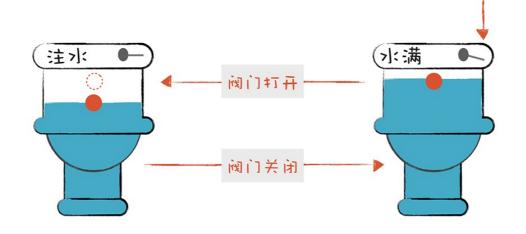
- **识别age这样的标识符。**它以字母开头,后面可以是字母或数字,直到遇到第一个既不是字母又不是数字的字符时结束。
- **识别>=这样的操作符。** 当扫描到一个>字符的时候,就要注意,它可能是一个GT(Greater Than,大于)操作符。但由于GE(Greater Equal,大于等于)也是以>开头的,所以再往下再看一位,如果是=,那么这个Token就是GE,否则就是GT。
- 识别45这样的数字字面量。当扫描到一个数字字符的时候,就开始把它看做数字,直到遇到非数字的字符。

这些规则可以通过手写程序来实现。事实上,很多编译器的词法分析器都是手写实现的,例如GNU的C语言编译器。

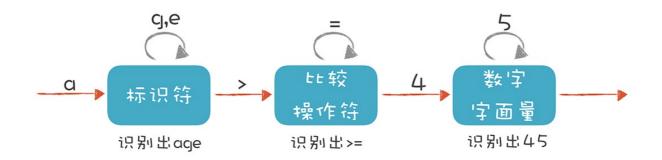
如果嫌手写麻烦,或者你想花更多时间陪恋人或家人,也可以偷点儿懒,用词法分析器的生成工具来生成,比如Lex(或其GNU版本,Flex)。这些生成工具是基于一些规则来工作的,这些规则用"正则文法"表达,符合正则文法的表达式称为"正则表达式"。生成工具可以读入正则表达式,生成一种叫"有限自动机"的算法,来完成具体的词法分析工作。

不要被"正则文法"和"有限自动机"吓到。正则文法是一种最普通、最常见的规则,写正则表达式的时候 用的就是正则文法。我们前面描述的几个规则,都可以看成口语化的正则文法。

有限自动机是有限个状态的自动机器。我们可以拿抽水马桶举例,它分为两个状态: "注水"和"水满"。 摁下冲马桶的按钮,它转到"注水"的状态,而浮球上升到一定高度,就会把注水阀门关闭,它转到"水 满"状态。



词法分析器也是一样,它分析整个程序的字符串,当遇到不同的字符时,会驱使它迁移到不同的状态。例如,词法分析程序在扫描age的时候,处于"标识符"状态,等它遇到一个>符号,就切换到"比较操作符"的状态。词法分析过程,就是这样一个个状态迁移的过程。



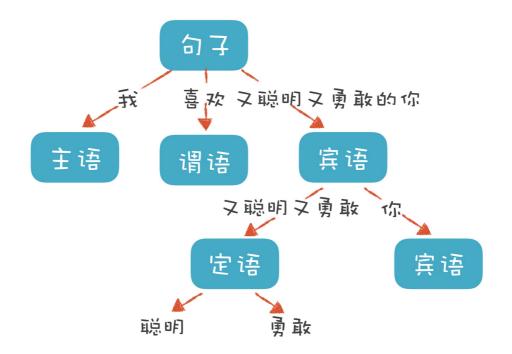
你也许熟悉正则表达式,因为我们在编程过程中经常用正则表达式来做用户输入的校验,例如是否输入了一个正确的电子邮件地址,这其实就是在做词法分析,你应该用过。

语法分析

编译器下一个阶段的工作是语法分析。词法分析是识别一个个的单词,而语法分析就是在词法分析的基础上识别出程序的语法结构。这个结构是一个树状结构,是计算机容易理解和执行的。

以自然语言为例。自然语言有定义良好的语法结构,比如,"我喜欢又聪明又勇敢的你"这个句子包含了"主、谓、宾"三个部分。主语是"我",谓语是"喜欢",宾语部分是"又聪明又勇敢的你"。其中宾语部分又可以拆成两部分,"又聪明又勇敢"是定语部分,用来修饰"你"。定语部分又可以分成"聪明"和"勇敢"两个最小的单位。

这样拆下来,会构造一棵树,里面的每个子树都有一定的结构,而这个结构要符合语法。比如,汉语是用"主谓宾"的结构,日语是用"主宾谓"的结构。这时,我们说汉语和日语的语法规则是不同的。



程序也有定义良好的语法结构,它的语法分析过程,就是构造这么一棵树。一个程序就是一棵树,这棵树叫做**抽象语法树**(Abstract Syntax Tree,AST)。树的每个节点(子树)是一个语法单元,这个单元的构成规则就叫"语法"。每个节点还可以有下级节点。

层层嵌套的树状结构,是我们对计算机程序的直观理解。计算机语言总是一个结构套着另一个结构,大的程序套着子程序,子程序又可以包含子程序。

接下来,我们直观地看一下这棵树长什么样子。 我在Mac电脑上打下这个命令:

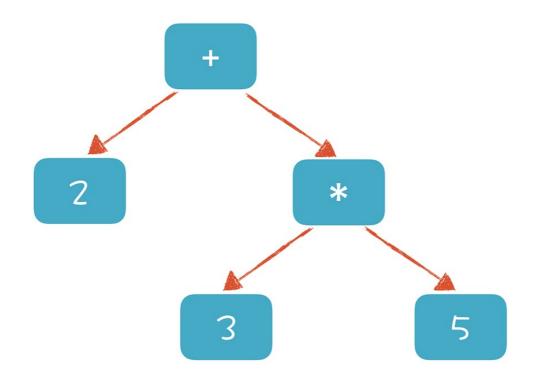
```
clang -cc1 -ast-dump hello.c
```

这个命令是运行苹果公司的C语言编译器来编译hello.c,-ast-dump参数使它输出AST,而不是做常规的编译。我截取了一部分输出结果给你看,从中你可以看到这棵树的结构。 试着修改程序,添加不同的语句,你会看到不同的语法树。

```
-CompoundStmt 0x7fad85855838 line:3:1, line:12:1>
|-DecIStmt 0x7fad85855280 cine:4:2, col:14>
|-VarDeci 0x7fad85855280 cine:4:2, col:6 used age 'int' cinit
|-IntegerLiteral 0x7fad85855206 col:12> 'int' 45
|-IfStmt 0x7fad85855708 cine:5:2, line:10:2>
|-<<NULL>>
|-<<NULL>>
|-ImplicitCastExpr 0x7fad85855388 <line:5:6, col:18> 'int' '>='
|-ImplicitCastExpr 0x7fad85855388 <line:5:6, col:18> 'int' '>='
|-ImplicitCastExpr 0x7fad85855385298 <col:6> 'int' \close 10:10 'ord 0x1 ord 0
```

如果你觉得这棵树还不够直观,可以参考我提供的<mark>网址</mark>,它能够生成JavaScript语言的AST,并以更加直观 的方式呈现。

在这个网址里输入一个可以计算的表达式,例如"2+3*5",你会得到一棵类似下图的AST。



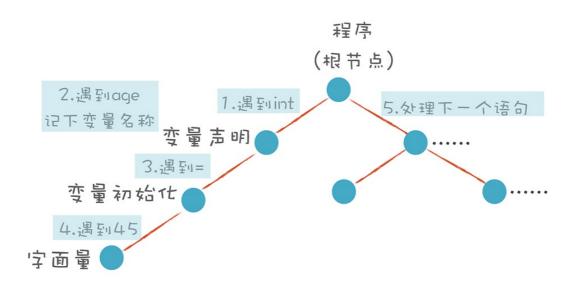
形成AST以后有什么好处呢?就是计算机很容易去处理。比如,针对表达式形成的这棵树,从根节点遍历整棵树就可以获得表达式的值。基于这个原理,我在后面的课程中会带你实现一个计算器,并实现自定义公式功能。

如果再把循环语句、判断语句、赋值语句等节点加到AST上,并解释执行它,那么你实际上就实现了一个脚本语言。而执行脚本语言的过程,就是遍历AST的过程。当然,在后面的课程中,我也会带你实际实现一个脚本语言。

好了,你已经知道了AST的作用,那么怎样写程序构造它呢?

一种非常直观的构造思路是自上而下进行分析。首先构造根节点,代表整个程序,之后向下扫描Token串,构建它的子节点。当它看到一个int类型的Token时,知道这儿遇到了一个变量声明语句,于是建立一个"变量声明"节点;接着遇到age,建立一个子节点,这是第一个变量;之后遇到=,意味着这个变量有初始化值,那么建立一个初始化的子节点;最后,遇到"字面量",其值是45。

这样,一棵子树就扫描完毕了。程序退回到根节点,开始构建根节点的第二个子节点。这样递归地扫描,直到构建起一棵完整的树。



这个算法就是非常常用的递归下降算法。是不是很简单? 你完全可以动手写出来。

递归下降算法是一种自顶向下的算法,与之对应的,还有自底向上的算法。这个算法会先将最下面的叶子节点识别出来,然后再组装上一级节点。有点儿像搭积木,我们总是先构造出小的单元,然后再组装成更大的单元。原理就是这么简单。

也许你会想,除了手写,有没有偷懒的、更省事的方法呢?多一些时间去陪家人总不是坏事。

你现在已经有了一定的经验,大可以去找找看有没有现成的工具,比如Yacc(或GNU的版本,Bison)、Antlr、JavaCC等。实际上,你可以在维基百科里找到一个挺大的清单,我把它放到了CSDN的<mark>博客</mark>上,其中对各种工具的特性做了比较。

顺理成章地,你还能找到很多开源的语法规则文件,改一改,就能用工具生成你的语法分析器。

很多同学其实已经做过语法解析的工作,比如编写一个自定义公式的功能,对公式的解析就是语法分析过程。另一个例子是分析日志文件等文本文件,对每行日志的解析,本质上也是语法分析过程。解析用XML、JSON写的各种配置文件、模型定义文件的过程,其实本质也是语法分析过程,甚至还包含了语义分析工作。

语义分析

好了,讲完了词法分析、语法分析,编译器接下来做的工作是语义分析。说白了,语义分析就是要让计算机 理解我们的真实意图,把一些模棱两可的地方消除掉。 以 "You can never drink too much water." 这句话为例。它的确切含义是什么?是 "你不能喝太多水",还是 "你喝多少水都不嫌多"?实际上,这两种解释都是可以的,我们只有联系上下文才能知道它的准确含义。

你可能会觉得理解自然语言的含义已经很难了,所以计算机语言的语义分析也一定很难。其实语义分析没那么复杂,因为计算机语言的语义一般可以表达为一些规则,你只要检查是否符合这些规则就行了。比如:

- 某个表达式的计算结果是什么数据类型? 如果有数据类型不匹配的情况,是否要做自动转换?
- 如果在一个代码块的内部和外部有相同名称的变量,我在执行的时候到底用哪个? 就像"我喜欢又聪明又勇敢的你"中的"你",到底指的是谁,需要明确。
- 在同一个作用域内,不允许有两个名称相同的变量,这是唯一性检查。你不能刚声明一个变量a,紧接着 又声明同样名称的一个变量a,这就不允许了。

语义分析基本上就是做这样的事情,也就是根据语义规则进行分析判断。

语义分析工作的某些成果,会作为属性标注在抽象语法树上,比如在age这个标识符节点和45这个字面量节点上,都会标识它的数据类型是int型的。

在这个树上还可以标记很多属性,有些属性是在之前的两个阶段就被标注上了,比如所处的源代码行号,这 一行的第几个字符。这样,在编译程序报错的时候,就可以比较清楚地了解出错的位置。

做了这些属性标注以后,编译器在后面就可以依据这些信息生成目标代码了,我们在编译技术的后端部分会 去讲。

课程小结

讲完语义分析,本节课也就告一段落了,我来总结一下本节课的重点内容:

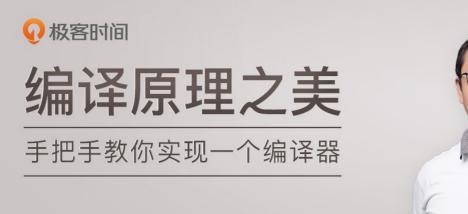
- 词法分析是把程序分割成一个个Token的过程,可以通过构造有限自动机来实现。
- 语法分析是把程序的结构识别出来,并形成一棵便于由计算机处理的抽象语法树。可以用递归下降的算法来实现。
- 语义分析是消除语义模糊,生成一些属性信息,让计算机能够依据这些信息生成目标代码。

我想让你知道,上述编译过程其实跟你的实际工作息息相关。比如,词法分析就是你工作中使用正则表达式的过程。而语法分析在你解析文本文件、配置文件、模型定义文件,或者做自定义公式功能的时候都会用到。

我还想让你知道,编译技术并没有那么难,它的核心原理是很容易理解的。学习之后,你能很快上手,如果 善用一些辅助生成工具会更省事。所以,我希望你通过学习这篇文章,已经破除了一些心理障碍,并跃跃欲 试,想要动手做点儿什么了!

一课一思

你有没有觉得,刚开始学编译原理中的某些知识点时特别难,一旦学通了以后,就会发出类似的感慨: "啊!原来就是这么回事!"欢迎在留言区与我分享你的感慨时刻。另外,你是否尝试实现过一个编译器,还颇有一些心得?可以在留言区与大家一起交流。



宫文学

北京物演科技CEO



新版升级:点击「探请朋友读」,20位好友免费读,邀请订阅更有现金奖励。

精选留言:

Simon 2019-08-14 18:29:17

之前基于ANTLR给游戏策划做了一套dsl 战斗技能解析器,策划只要在文件中配置技能的效果就行,战斗的时候根据配置的表达式去解析并计算伤害啥的。感觉策划们用的很爽,新增加技能或者修改技能效果再也不用找开发了。开发感觉更爽。 ③⑤ [12赞]

作者回复2019-08-14 19:15:25

对的,做DSL能够给具体的领域带来很大的帮助!感谢你分享游戏领域的经验!

我知道游戏领域有人在做DSL,我对这个领域不太了解。马云也曾经参观国外的一个游戏公司,发现他们 把平台做的很好,能够支持很多游戏的快速研发。他回来以后,在阿里提了中台的概念,目前在企业应用 领域很流行。中台呀,游戏平台呀,编译原理都能发挥作用。

• coder 2019-08-14 21:39:55

我做过一款已经投入商用的编译器,从编译器的前端到中端的优化,再到后端针对某个特定architecture 的代码生成以及优化,完整地趟过一遍,编译器的实现是基于clang和llvm的,目前的感觉是,工程经验确实积累了不少。antlr,flex,bison等这些工具也都用过。所以在看到课程目录时,感觉比较熟悉,目录中提到的东西都是知道的。

但是我目前的感觉是,自己在理论方面的积累还是有些欠缺的,那些PL相关的理论也同样重要,包括图灵机,状态机,计算模型,lambda演算,类型和类型系统等,所以希望老师也能够也讲一下这部分理论②②②[7赞]

作者回复2019-08-14 22:29:49

看来我要跟你学习才对:)

这门课是实战和原理并重。但在设计上,会先让同学们建立对编译的直观感受,然后再引导到对算法的兴趣上。所以,在前端部分,我把算法的总结和提升放到了最后部分。因为这个时候,大家都已经没有陌生感、恐惧感了,学算法也就顺理成章了。

你的经验已经比大部分同学多。我也争取把理论这部分也在课程里搞好!

Fan 2019-08-14 19:46:51

希望后面有具体的一些demo [7赞]

作者回复2019-08-14 20:06:26

有的,有很多demo。这门课不是纯讲理论,而是拿实操带动我们学理论。 第一节课是前端技术的概述。第二节就开始做例子了!示例代码到时候也释放出来。

• 旺旺 2019-08-14 18:08:08

讲的还是很易懂的, №! [5赞]

作者回复2019-08-14 19:19:38

谢谢鼓励。讲的易懂,是我准备这门课程最大的挑战。我会继续努力!

X中倪 2019-08-14 17:06:04

盘他 [5赞]

作者回复2019-08-14 19:21:25 **对头!**

• 公众号: 业余草 2019-08-15 09:08:21

BAT为什么没有造出一门语言的轮子? [3赞]

作者回复2019-08-15 10:20:21

首先呢,编译原理不仅仅是造大家通用的语言。有很多是用来解决领域问题的。比如,好像阿里内部就有一个语言,叫cava,是跟它的搜索引擎配合的。

其次,我们做这些底层平台的时候,都要涉及编译。还是拿阿里的druid开源项目说事,它就手写了一个 高速的sql parser。其他几家大的互联网公司肯定也有不少这种应用。

华为的方舟编译器,不是也很争气吗?有人说它没有多少创新,但它就是效果显著呀。

我跟大家一样,都期盼带有中国血统的、全球人都用的语言诞生出来。我相信时间不远了。这种事情需要 技术底蕴,更重要的是需要产业发言权。这方面,我们是越来越强了!大家一起期盼!

• William 2019-08-14 23:45:16

分析一下自己做得一些摘录。

trick:

mac 下的 clang命令可以编译C语言代码。

术语:

正则文法 最普通、最常见的规则

有限自动机 有限个状态的自动机器

词法分析 lexical analysis -> 分词

- *实现原理:有限自动机
- * 现成的词法分析工具: Lex、GNU Flex

语法分析 parser -> 根据语法规则识别出程序的语法结构 (抽象语法树AST)

- * 需要考虑优先级等等
- * 递归下降方法
- * 现成的语法分析工具: Yacc、GNU Bison、Antlr、JavaCC

语义分析 semantic analysis -> 上下文分析、消除歧义

- * 变量引用消解、作用域
- * 合法性检查
- *数据类型标识
- * 语义分析的某些结果,会作为属性标注在AST上

[3赞]

作者回复2019-08-15 08:16:57

记得这么认真!

Great!

• halweg 2019-08-14 18:15:56

很棒!

之前看了一本从逻辑门构建一台带操作系统的计算机的书,卡在了那本书里jack的语言的编译上, 这次希望可以搞懂 [3赞]

作者回复2019-08-14 19:18:07

如果我的哪一讲让你卡壳了,你要告诉我!我单独给你讲:)

• frazer 2019-08-15 09:20:56

老师,不涉及逻辑分析么? [2赞]

作者回复2019-08-15 10:14:37

当然要涉及。

但我重视帮大家建立直觉的理解。一旦你直觉上理解那件事了,对它有感觉了,去做逻辑推理就很顺利了

我觉得,这种直接认知,是学好一门课的关键。

Mr.J 2019-08-15 01:43:33

老师好,词法分析好理解一些,即程序识别出每个词汇,语法分析这个,拆分AST,打个比方,一个java 代码:

class A {

int a = 2;

boolean = false;

}

语法分析时,把这个拆分AST,比如,遇到class,定义为根节点,两个关键字int 和boolean为两个子节点,每个子节点下面继续拆分,可以这样理解不,一条完整的java代码,就是从最后一个自己点一直向上到某个节点?

语义分析这个是在整个上下文中去进行的,定了全局变量a,在方法中使用a时,能够知道这个是在全居中定义过的那个a? [2赞]

作者回复2019-08-15 08:08:53

你大的概念理解完全正确。

这个类语法分析后会变成一棵树。像这样的语法,解析起来是很简单的。反倒是像表达式这样看似很简单的语法,解析起来反倒有难度。在后面的课程里会深入到细节。

语义分析的关键点你也抓住了,就是上下文。语法阶段是上下文无关的,语义阶段则专门处理上下文。 加油!

William 2019-08-14 23:44:53

请问老师,JavaScript解释器 V8引擎或者Node.js解释器里内置了Antlr这些语法分析器吗,还是自己实现了一套? [2赞]

作者回复2019-08-15 08:21:09

这些级别的项目,还是自己写的。因为会最契合项目的需求。比如速度、资源消耗、解析过程等方面的需求。因为对V8的编写者来说,语法分析这个层面的事情真的不是事情。你如果把前端技术学透,也不会觉得这是个事。

另一方面,对于大多数项目来说,借助工具就足够了。比如,Hibernate,比如mysql workbench。后者就是用的antlr。

• 雲至 2019-08-14 17:45:58

老师能讲一个具体树最好了[2赞]

作者回复2019-08-14 19:20:41

后面的课程中,有好多棵具体的树,慢慢来!

胖胖胖 2019-08-14 21:39:23

感觉大概明白啥意思了,但想总结出自己的笔记,发现像词法分析中正则这些概念大概理解了但没法清晰的定义出来,老师阔以在这些讲解之后给一个清晰的定义,方便我们验证自己的理解吗。最好有一些好的和当堂课相关,更深入一点的读物推荐。就像计算机组成原理专栏的徐老师的那种方式。纯属个人建议。然后确实讲的很清楚,感谢老师! [1赞]

作者回复2019-08-14 22:32:18

好的。第一讲是前端技术的概述,我的目标是把全貌展现一下。接着,就进入每个具体知识点的讲解。下 一讲就开始把词法分析的细节展开了。

好的,我会在课程里注意推荐读物。课程体系中,我们专门安排了答疑的部分,估计到时候会放到那里面

信 2019-08-14 20:44:44

babel的编译器大概看过看不太懂,我是做前端的,学了老师的课程能不能做一个页面设计器呢[1赞]

作者回复2019-08-14 21:43:19

我自己做过表单设计器、报表设计器,跟你说的页面设计器应该有相似之处。

界面模板引擎啦、前端的DSL啦,也都与你的兴趣有关联吧?这些都与编译技术有关。

我后面在课程里还提供了一个报表系统的原型系统。估计也会对你有启发。也就是说,做前端方面的工具 ,真的经常用到编译技术。

• kirogiyi 2019-08-15 23:12:52

有一种回归计算机本质的感觉,向宫老师多学习。

重 2019-08-15 23:10:31

不错

• 傲娇的小宝 2019-08-15 23:03:49

感觉就是类似XML的实现,节点类似xml的节点,语义分析的成果就像xml上的属性。似乎很多东西其实都是树形结构,通过属性记录一些东西,节点保存东西,运行的时候两相结合。这些操作的根本目的就是保存住有效信息并且有效读取。

Rockbean 2019-08-15 23:02:11

请教老师,AST可不可以转成可视化UML

Rockbean 2019-08-15 22:50:34

想起标识符的命名为什么不能用数字开头,扫描到了数字,立马认为这个token是数字,不作标识符处理

• Vivian 2019-08-15 22:20:42 看到了AST